Каждая оценка с доказательством

Система проверяет чаты и звонки по чек-листу, ставит балл по каждому критерию и показывает реплику, на которой основано решение.

Ручная проверка диалогов не масштабируется

Контролёр читает переписку, сверяется с 8 критериями, считает веса, отдельно учитывает N/A и грубые нарушения.

Три языка, чаты и расшифровки звонков с ошибками распознавания речи.

Главная метрика жюри: насколько оценки системы совпадают с эталоном на 10 новых диалогах.

Поэтому мы строили систему вокруг точности и проверяемости, а не вокруг одного большого промпта.

Как это работает

Один критерий, один точный вопрос

01

Диалог

Из API по group_id, из файла или вставкой. Чек-лист выбирается по каналу: чат или звонок.

02

8 отдельных проверок

У каждого критерия свой промпт с правилами и условиями N/A. Оценивается только оператор, не бот.

03

Жюри моделей

Две модели решают независимо. При расхождении решает третья, самая сильная.

04

Проверка цитат

Каждая цитата ищется в транскрипте дословно. Выдуманная цитата отклоняется, запрос повторяется.

05

Итог считает код

Веса, перераспределение N/A и округление считаются детерминированно, без участия модели.

Жюри из трёх моделей

Две модели голосуют, третья разрешает спор

Claude Haiku 5.5

Присяжный: быстрый взгляд

Claude Sonnet 5.5

Присяжный: глубокий разбор

→

Claude Opus 5.5

Судья. Видит транскрипт и оба мнения, решает по фактам, а не большинством.

85%

оценок присяжные дали одинаково (444 из 520)

76

спорных случаев из 520 решил судья (шкалы — медиана 3 ответов); все помечены «на проверку»

Данные: прогон на 65 DEV-диалогах

Пример из DEV · p1-ru-023 · итог 61.54 · грубая ошибка

Решение можно проверить за секунды

01	**Установление контакта**	**Да**	*«Здравствуйте, я Марк.»*
03	**Идентификация**	**N/A**	*Общий вопрос про облигации, данные клиента не раскрывались*
04	**Консультация**	**0**	*Путь в «Котировках» назван, но предложена платная консультация в обход компании — по правилу 0*
06	**Ведение диалога**	**10**	*Присяжные: 7 и 10. Судья Opus (вслепую): 10*
07	**Завершение**	**Нет**	*«Хорошо. Всего доброго.» Прощание есть, итога и предложения помощи нет*
08	**Грубые ошибки**	**Да**	*«Можете дать личный номер? Вечером созвонюсь с вами и за плату объясню…»*

Обоснования и цитаты сгенерированы системой, номера реплик ведут в транскрипт

Модель оценивает, код считает

$$\text{итог} = \Sigma\ (\text{балл}_i\ /\ \text{макс}_i) \times \text{вес}_i \times 100\ /\ \Sigma\ \text{вес}_{\text{применимых}}$$

N/A не штрафует

Неприменимый критерий исключается, его вес распределяется пропорционально. Максимум всегда 100.

Округление по правилу

Half-up до двух знаков: 50.625 → 50.63. Покрыто тестом.

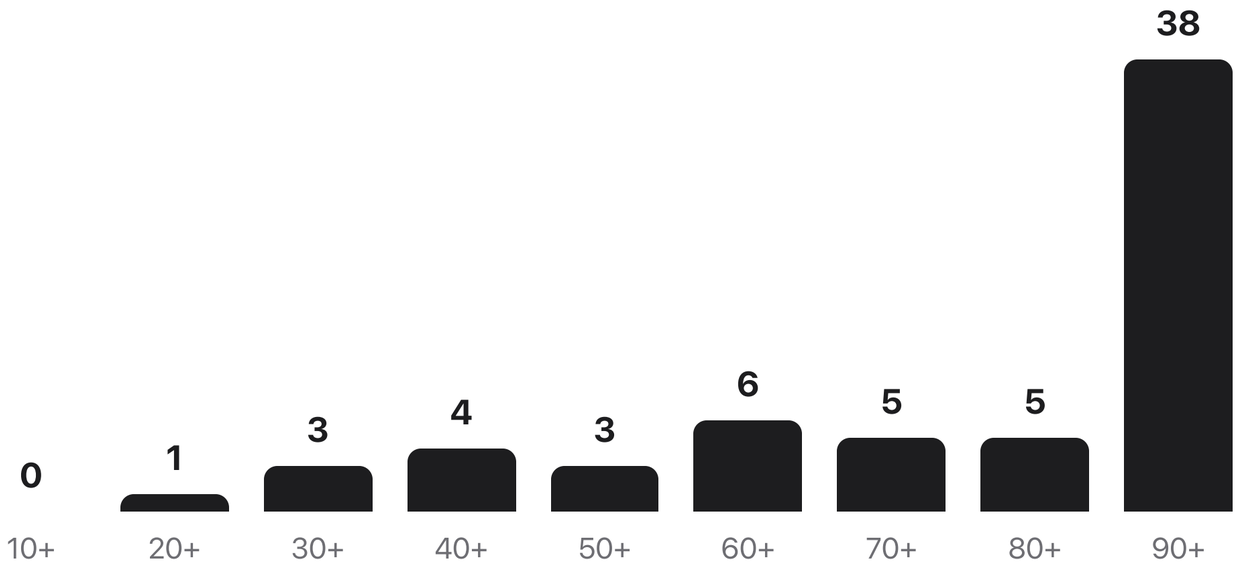
Грубые ошибки отдельно

Флаг не смешивается с баллом и виден в списке сразу.

Автотесты в CI

N/A, шкалы, перераспределение, округление, цитаты, формат сдачи, апелляции.

65 диалогов, ноль сбоев



Распределение итоговых баллов

80.41

средний балл

5

диалогов с грубой ошибкой: перевод денег на карту оператора, платная консультация в обход компании, оскорбление

60 чатов · 5 звонков

русский, казахский, английский

Точность на реальных DEV-диалогах человеком пока не измерена: на отложенном синтетическом наборе 0.95

Каскад · `--preset cascade`

Каскад: в 11–18 раз дешевле при том же качестве

Уровень 1 · 73–82% критериев

Jev 1.14

Оценивает все 8 критериев за $0.00053. Уверенные ответы остаются.

Уровень 2 · 15–19%

Claude Haiku

Низкая уверенность и сложные шкалы 04/05/06. Даёт цитаты-доказательства.

Уровень 3 · 2–7%

Claude Sonnet

Разногласия и признаки грубой ошибки.

0.963

отложенный набор (жюри: 0.95)

0.948

совпадение с жюри на 65 DEV

$0.004–0.015

за диалог: отложенный / DEV (жюри: $0.0745 / $0.158)

5 / 5

грубых ошибок на DEV найдены

Jev в одиночку 0.933 · Qwen3-8B-AWQ в одиночку 0.775 (отложенный набор) · docs/OSS_ROUTER.md

Своя модель на HuggingFace

База

Qwen3-8B

Open-weight. Без дообучения 0.787 на отложенном наборе (bf16): для первого уровня слабовата.

Дообучение

QLoRA, 16 шагов (≈ 0.32 эпохи)

Учится на вердиктах нашего жюри: критерий, значение, цитата.

Запуск

На вашей GPU

vLLM + LoRA-адаптер. Данные диалогов не уходят из контура.

0.787

отложенный набор после 16 шагов (база 0.787, MAE 12.17 → 10.43)

80 МБ

адаптер на HuggingFace: useing/cqa-qwen3-8b-lora

`huggingface.co/useing/cqa-qwen3-8b-lora`

адаптер опубликован · docs/FINETUNE.md

Отложенный синтетический набор, 10 диалогов: совпадение не выросло, MAE снизилась; это прототип

Контролёр остаётся главным

Без логина

Открыл ссылку и работаешь. Загрузка группы и оценка в одну кнопку.

Ручная проверка

Любой критерий можно переоценить. Правки человека хранятся отдельно, итог пересчитывается, видна разница AI и человека.

Подсветка доказательств

Клик по оценке подсвечивает реплику в транскрипте.

Аудио звонков

Плеер с переходом к реплике по времени транскрипта.

Редактор чек-листов

Добавить, заменить, перевесить критерий. Отдельные чек-листы для чатов и звонков.

Экспорт

results.json в формате сдачи 1.0, JSON и CSV.

Новый чек-лист без программиста

Изменили критерий — пересчитываются только затронутые оценки. Кэш привязан к тексту критерия и диалогу.

Поменяли вес — итог пересчитывается мгновенно, без обращения к модели.

Любой провайдер. Модели меняются в конфиге. Поддержан OpenAI-совместимый endpoint для локальной LLM (Ollama, vLLM).

Звонки. Отдельный чек-лист учитывает устную речь: логику разговора, паузы, понятность объяснений.

Спорная оценка — в два шага

1. Оспорить

На карточке критерия — кнопка «Оспорить» и обязательный комментарий. Апелляция попадает в очередь со счётчиком.

2. Решить

Проверяющий видит комментарий, вердикт AI с цитатами и фрагмент диалога; подтверждает или меняет оценку с обязательной причиной.

Итог пересчитывается

Изменение записывается как правка человека; карточка показывает исходную оценку, решение и итог.

Журнал

Кто, когда, комментарий, решение и причина сохраняются для каждой апелляции.

Формат сдачи

results.json 1.0 — по приложению к гайду

results/dev и results/prod

65 записей DEV и ровно 10 контрольных; диалог с ошибкой остаётся в файле со status=error, без нулевой оценки.

8 кодов критериев

contact … critical: true / false / null или шаг шкалы до учёта веса; final_score с двумя знаками и critical_flag.

Реплики с №1

evidence_turns — по исходному массиву транскрипта; та же нумерация в промпте, интерфейсе и API.

Проверка перед push

python -m cqa validate: схема, значения, дубли ID, число записей.

Контрольный этап

10 новых диалогов примерно за минуту

```
make submit GROUP=<ID> → results/prod/results.json
```

~1 мин

параллельная обработка

~$1.6

за 10 диалогов ($0.16 за диалог; $10.28 за 65 на DEV)

0

заготовленных ответов: каждый диалог анализируется заново

Или кнопка «Загрузить группу и оценить» в интерфейсе

Где мы приняли решение сами

«Первый ответ» в критерии 01

Первая реплика живого оператора, даже если до него отвечал бот.

Время первой реакции

Ожидание в очереди не снижает оценку ведения диалога: по условию оно не оценивается.

Завершение строго по рубрике

Одного «Хорошего дня» мало: нужен итог или предложение помощи плюс прощание.

Всё настраивается

Каждое допущение вынесено флагом в YAML и меняется за минуту.