Freedom Broker · Хакатон · Кейс CQA

Каждая оценка с доказательством

Система проверяет чаты и звонки по чек-листу, ставит балл по каждому критерию и показывает реплику, на которой основано решение.

RU · KZ · EN · чаты и звонки

Ручная проверка диалогов не масштабируется

Контролёр читает переписку, сверяется с 8 критериями, считает веса, отдельно учитывает N/A и грубые нарушения.

Три языка, чаты и расшифровки звонков с ошибками распознавания речи.

Главная метрика жюри: насколько оценки системы совпадают с эталоном на 10 новых диалогах.

Поэтому мы строили систему вокруг точности и проверяемости, а не вокруг одного большого промпта.

Один критерий, один точный вопрос

01

Диалог

Из API по group_id, из файла или вставкой. Чек-лист выбирается по каналу: чат или звонок.

02

8 отдельных проверок

У каждого критерия свой промпт с правилами и условиями N/A. Оценивается только оператор, не бот.

03

Жюри моделей

Две модели решают независимо. При расхождении решает третья, самая сильная.

04

Проверка цитат

Каждая цитата ищется в транскрипте дословно. Выдуманная цитата отклоняется, запрос повторяется.

05

Итог считает код

Веса, перераспределение N/A и округление считаются детерминированно, без участия модели.

Жюри из трёх моделей

Две модели голосуют, третья разрешает спор

Claude Haiku 5.5

Присяжный: быстрый взгляд

Claude Sonnet 5.5

Присяжный: глубокий разбор

→

Claude Opus 5.5

Судья. Видит транскрипт и оба мнения, решает по фактам, а не большинством.

84%

оценок присяжные дали одинаково

81

спорных случаев из 520 решил судья

Данные: прогон на 65 DEV-диалогах

Пример из DEV · p1-ru-023 · итог 84.62 · грубая ошибка

Решение можно проверить за секунды

01	**Установление контакта**	**Да**	*«Здравствуйте, я Марк.»*
03	**Идентификация**	**N/A**	*Общий вопрос про облигации, данные клиента не раскрывались*
04	**Консультация**	**15**	*«Откройте „Котировки“. Если знаете название или тикер, введите его в строку поиска.»*
06	**Ведение диалога**	**10**	*Присяжные: 7 и 10. Судья Opus: 10*
07	**Завершение**	**Нет**	*«Хорошо. Всего доброго.» Прощание есть, итога и предложения помощи нет*
08	**Грубые ошибки**	**Да**	*«Можете дать личный номер? Вечером созвонюсь с вами и за плату объясню...»*

Обоснования и цитаты сгенерированы системой, номера реплик ведут в транскрипт

Модель оценивает, код считает

$$\text{итог} = \Sigma\ (\text{балл}_i\ /\ \text{макс}_i) \times \text{вес}_i \times 100\ /\ \Sigma\ \text{вес}_{\text{применимых}}$$

N/A не штрафует

Неприменимый критерий исключается, его вес распределяется пропорционально. Максимум всегда 100.

Округление по правилу

Half-up до двух знаков: 50.625 → 50.63. Покрыто тестом.

Грубые ошибки отдельно

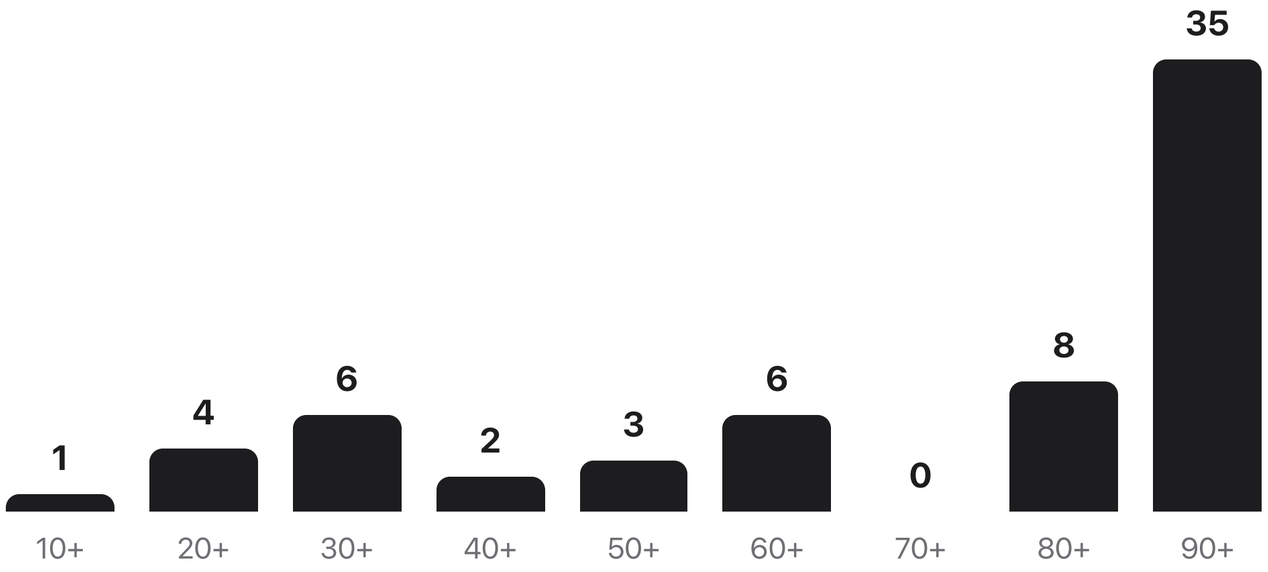
Флаг не смешивается с баллом и виден в списке сразу.

13 юнит-тестов

Все N/A, шкалы, перераспределение, граничные случаи округления.

Результаты на DEV

65 диалогов, ноль сбоев



Распределение итоговых баллов

75.95

средний балл

5

диалогов с грубой ошибкой: перевод денег на карту оператора, платная консультация в обход компании, оскорбление

60 чатов · 5 звонков

русский, казахский, английский

Эталонной разметки нет. Ручная сверка 8 диалогов по рубрике выполнена

Контролёр остаётся главным

Без логина

Открыл ссылку и работаешь. Загрузка группы и оценка в одну кнопку.

Ручная проверка

Любой критерий можно переоценить. Правки человека хранятся отдельно, итог пересчитывается, видна разница AI и человека.

Подсветка доказательств

Клик по оценке подсвечивает реплику в транскрипте.

Аудио звонков

Плеер с переходом к реплике по времени транскрипта.

Редактор чек-листов

Добавить, заменить, перевесить критерий. Отдельные чек-листы для чатов и звонков.

Экспорт

JSON и CSV: строка на диалог, столбец на критерий, итог и флаг.

Новый чек-лист без программиста

Изменили критерий — пересчитываются только затронутые оценки. Кэш привязан к тексту критерия и диалогу.

Поменяли вес — итог пересчитывается мгновенно, без обращения к модели.

Любой провайдер. Модели меняются в конфиге. Поддержан OpenAI-совместимый endpoint для локальной LLM (Ollama, vLLM).

Звонки. Отдельный чек-лист учитывает устную речь: логику разговора, паузы, понятность объяснений.

Контрольный этап

10 новых диалогов примерно за минуту

```
python -m cqa evaluate --group <ID>
```

~1 мин

параллельная обработка

~$2

за 10 диалогов

0

заготовленных ответов: каждый диалог анализируется заново

Или кнопка «Загрузить группу и оценить» в интерфейсе

Где мы приняли решение сами

«Первый ответ» в критерии 01

Первая реплика живого оператора, даже если до него отвечал бот.

Время первой реакции

Ожидание в очереди не снижает оценку ведения диалога: по условию оно не оценивается.

Завершение строго по рубрике

Одного «Хорошего дня» мало: нужен итог или предложение помощи плюс прощание.

Всё настраивается

Каждое допущение вынесено флагом в YAML и меняется за минуту.

Точно. Доказуемо. Под контролем человека.

Жюри из трёх моделей, проверка каждой цитаты, расчёт в коде и интерфейс, где последнее слово за контролёром.