# Каждая оценка с доказательством

Система проверяет чаты и звонки по чек-листу, ставит балл по каждому критерию и показывает реплику, на которой основано решение.

# Ручная проверка диалогов не масштабируется

Контролёр читает переписку, сверяется с 8 критериями, считает веса, отдельно учитывает N/A и грубые нарушения.

Три языка, чаты и расшифровки звонков с ошибками распознавания речи.

**Главная метрика жюри:** насколько оценки системы совпадают с эталоном на 10 новых диалогах.

Поэтому мы строили систему вокруг точности и проверяемости, а не вокруг одного большого промпта.

Как это работает

# Один критерий, один точный вопрос

01

### Диалог

Из API по group_id, из файла или вставкой. Чек-лист выбирается по каналу: чат или звонок.

02

### 8 отдельных проверок

У каждого критерия свой промпт с правилами и условиями N/A. Оценивается только оператор, не бот.

03

### Жюри моделей

Две модели решают независимо. При расхождении решает третья, самая сильная.

04

### Проверка цитат

Каждая цитата ищется в транскрипте дословно. Выдуманная цитата отклоняется, запрос повторяется.

05

### Итог считает код

Веса, перераспределение N/A и округление считаются детерминированно, без участия модели.

Жюри из трёх моделей

# Две модели голосуют, третья разрешает спор

### Claude Haiku 5.5

Присяжный: быстрый взгляд

### Claude Sonnet 5.5

Присяжный: глубокий разбор

→

### Claude Opus 5.5

Судья. Видит транскрипт и оба мнения, решает по фактам, а не большинством.

**85%**

оценок присяжные дали одинаково (444 из 520)

**76**

спорных случаев из 520 решил судья (шкалы — медиана 3 ответов); все помечены «на проверку»

Данные: прогон на 65 DEV-диалогах

Пример из DEV · p1-ru-023 · итог 61.54 · грубая ошибка

# Решение можно проверить за секунды

| | | | |
|---|---|---|---|
| 01 | **Установление контакта** | **Да** | *«Здравствуйте, я Марк.»* |
| 03 | **Идентификация** | **N/A** | *Общий вопрос про облигации, данные клиента не раскрывались* |
| 04 | **Консультация** | **0** | *Путь в «Котировках» назван, но предложена платная консультация в обход компании — по правилу 0* |
| 06 | **Ведение диалога** | **10** | *Присяжные: 7 и 10. Судья Opus (вслепую): 10* |
| 07 | **Завершение** | **Нет** | *«Хорошо. Всего доброго.» Прощание есть, итога и предложения помощи нет* |
| 08 | **Грубые ошибки** | **Да** | *«Можете дать личный номер? Вечером созвонюсь с вами и за плату объясню…»* |

Обоснования и цитаты сгенерированы системой, номера реплик ведут в транскрипт

# Модель оценивает, код считает

$$итог = \Sigma\ (балл_i\ /\ макс_i) \times вес_i \times 100\ /\ \Sigma\ вес_{применимых}$$

## N/A не штрафует

Неприменимый критерий исключается, его вес распределяется пропорционально. Максимум всегда 100.

## Округление по правилу

Half-up до двух знаков: 50.625 → 50.63. Покрыто тестом.

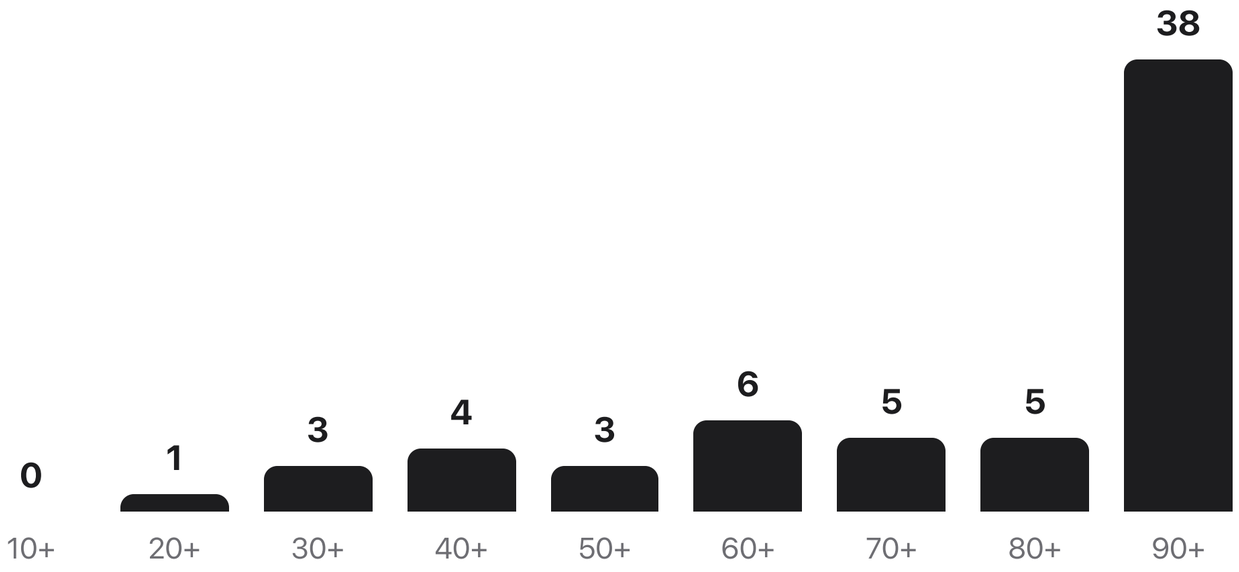
## Грубые ошибки отдельно

Флаг не смешивается с баллом и виден в списке сразу.

## 192 автотеста

N/A, шкалы, перераспределение, округление, цитаты, формат сдачи, апелляции.

# 65 диалогов, ноль сбоев




Распределение итоговых баллов

**80.41**

средний балл

**5**

диалогов с грубой ошибкой: перевод денег на карту оператора, платная консультация в обход компании, оскорбление

**60 чатов · 5 звонков**

русский, казахский, английский

Точность на реальных DEV-диалогах человеком пока не измерена: на отложенном синтетическом наборе 0.95

Каскад · `--preset cascade`

# Каскад: в 10–40 раз дешевле при том же качестве

Уровень 1 · 73–82% критериев

### Jev 1.14

Оценивает все 8 критериев за $0.00053. Уверенные ответы остаются.

Уровень 2 · 15–19%

### Claude Haiku

Низкая уверенность и сложные шкалы 04/05/06. Даёт цитаты-доказательства.

Уровень 3 · 3–7%

### Claude Sonnet

Разногласия и признаки грубой ошибки.

**0.963**

отложенный набор (жюри: 0.95)

**0.948**

совпадение с жюри на 65 DEV

**$0.004–0.015**

за диалог (жюри: $0.16)

**5 / 5**

грубых ошибок на DEV найдены

Jev в одиночку 0.934 · Qwen3-8B в одиночку 0.775 · docs/OSS_ROUTER.md

# Своя модель на HuggingFace

База

### Qwen3-8B

Open-weight. Без дообучения 0.775 на отложенном наборе: для первого уровня слабовата.

Дообучение

### QLoRA, 1 эпоха

Учится на вердиктах нашего жюри: критерий, значение, цитата.

Запуск

### На вашей GPU

vLLM + LoRA-адаптер. Данные диалогов не уходят из контура.

## — (в процессе)

отложенный набор после дообучения

## — (в процессе)

доля критериев без эскалации

**`huggingface.co/useing/cqa-qwen3-8b-lora`**

публикуется · docs/FINETUNE.md

Числа после дообучения ещё не измерены — заполним из реального прогона

# Контролёр остаётся главным

## Без логина

Открыл ссылку и работаешь. Загрузка группы и оценка в одну кнопку.

## Ручная проверка

Любой критерий можно переоценить. Правки человека хранятся отдельно, итог пересчитывается, видна разница AI и человека.

## Подсветка доказательств

Клик по оценке подсвечивает реплику в транскрипте.

## Аудио звонков

Плеер с переходом к реплике по времени транскрипта.

## Редактор чек-листов

Добавить, заменить, перевесить критерий. Отдельные чек-листы для чатов и звонков.

## Экспорт

results.json в формате сдачи 1.0, JSON и CSV.

# Новый чек-лист без программиста

**Изменили критерий** — пересчитываются только затронутые оценки. Кэш привязан к тексту критерия и диалогу.

**Поменяли вес** — итог пересчитывается мгновенно, без обращения к модели.

**Любой провайдер.** Модели меняются в конфиге. Поддержан OpenAI-совместимый endpoint для локальной LLM (Ollama, vLLM).

**Звонки.** Отдельный чек-лист учитывает устную речь: логику разговора, паузы, понятность объяснений.

# Спорная оценка — в два шага

## 1. Оспорить

На карточке критерия — кнопка «Оспорить» и обязательный комментарий. Апелляция попадает в очередь со счётчиком.

## 2. Решить

Проверяющий видит комментарий, вердикт AI с цитатами и фрагмент диалога; подтверждает или меняет оценку с обязательной причиной.

## Итог пересчитывается

Изменение записывается как правка человека; карточка показывает исходную оценку, решение и итог.

## Журнал

Кто, когда, комментарий, решение и причина сохраняются для каждой апелляции.

Формат сдачи

# results.json 1.0 — по приложению к гайду

## results/dev и results/prod

65 записей DEV и ровно 10 контрольных; диалог с ошибкой остаётся в файле со status=error, без нулевой оценки.

## 8 кодов критериев

contact … critical: true / false / null или шаг шкалы до учёта веса; final_score с двумя знаками и critical_flag.

## Реплики с №1

evidence_turns — по исходному массиву транскрипта; та же нумерация в промпте, интерфейсе и API.

## Проверка перед push

python -m cqa validate: схема, значения, дубли ID, число записей.

Контрольный этап

# 10 новых диалогов примерно за минуту

```
make submit GROUP=<ID> → results/prod/results.json
```

**~1 мин**

параллельная обработка

**~$1.6**

за 10 диалогов ($0.16 за диалог; $10.28 за 65 на DEV)

**0**

заготовленных ответов: каждый диалог анализируется заново

Или кнопка «Загрузить группу и оценить» в интерфейсе

# Где мы приняли решение сами

### «Первый ответ» в критерии 01

Первая реплика живого оператора, даже если до него отвечал бот.

### Время первой реакции

Ожидание в очереди не снижает оценку ведения диалога: по условию оно не оценивается.

### Завершение строго по рубрике

Одного «Хорошего дня» мало: нужен итог или предложение помощи плюс прощание.

### Всё настраивается

Каждое допущение вынесено флагом в YAML и меняется за минуту.

# Точно. Доказуемо. Под контролем человека.

Жюри из трёх моделей, проверка каждой цитаты, расчёт в коде и интерфейс, где последнее слово за контролёром.